

Machine Learning en tiempos de IA

Qué necesitas saber cuando el código ya no es la barrera.

Sofia Dextre


Hack with DSC | PUCP

- 1 IA, Machine Learning y Deep Learning.
- 2 Tipos de machine learning
- 3 Criterios de selección según los datos y el contexto.
- 4 Metodología de modelamiento.
- 5 Caso práctico

01

IA, Machine Learning y Deep Learning.

Entender qué herramienta necesitamos y qué podemos esperar de ella.



- **INTELIGENCIA ARTIFICIAL**

Técnicas que permiten a una máquina realizar tareas inteligentes mediante reglas programadas manualmente o algoritmos que aprenden de datos.

- **MACHINE LEARNING**

Tipo de IA que aprende patrones a partir de datos, sin programar todas las reglas.

- **DEEP LEARNING**

Tipo de ML que utiliza redes neuronales con múltiples capas para aprender patrones complejos.

IA basada en reglas

Es fácil de entender y controlar. No necesita entrenamiento.

No aprende ni se adapta. Es difícil mantener muchas reglas y excepciones.

Ejemplo: chatbot basado en reglas

Bot: ¡Hola! Elige una opción:

1. Consultar saldo
- 2. Bloquear tarjeta**
3. Hablar con un asesor

Usuario: 2

Bot: Te ayudaré a bloquear tu tarjeta.

Reglas programadas

Si opción = 1 → Consultar saldo

Si opción = 2 → Bloquear tarjeta

Si opción = 3 → Contactar asesor

Machine Learning

Funciona muy bien con datos tabulares. Requiere menos datos y capacidad computacional.

Requiere preparar los datos y definir características relevantes para el modelo.

Ejemplo: detección de fraude

Transacciones históricas → Entrenamiento → **Modelo aprendido**


Nueva transacción → **Modelo aprendido** → **$P(\text{fraude}) = 92 \%$**

Deep Learning

Aprende automáticamente características y relaciones complejas.

Requiere más datos y cómputo; suele ser menos interpretable.

Ejemplo: visión por computadora



Clasificar → Localizar → Detectar → Segmentar

02

Tipos de machine learning

Elegir el enfoque adecuado según el objetivo y los datos disponibles

Supervisado

Clasificación

- Regresión logística
- Random Forest
- SVC

Regresión

- Regresión lineal
- Random Forest
- SVR

No supervisado

Clustering

- k-means
- DBSCAN
- Mezclas gaussianas

Reducción de dimensionalidad

- PCA
- UMAP
- Autoencoder profundo (DL)

Semisupervisado

- Self-training
- Label Propagation
- FixMatch (DL)

Por refuerzo

- Q-learning
- SARSA
- DQN (DL)

03

Criterios de selección según los datos y el contexto.

Elegir qué modelos probar según la evidencia y las condiciones de uso.

Observamos que parte de nuestros clientes reduce su actividad y termina abandonando. Queremos diseñar una estrategia de retención. Podemos contactar como máximo al 10 % cada mes.

Clasificación

¿Qué queremos saber?	¿Qué buscamos predecir o identificar?	¿Para qué lo usaríamos?
¿Quiénes podrían abandonar el banco?	1: se fuga en los próximos 90 días. 0: no se fuga en ese periodo.	Identificar posibles fugas y evaluar acciones preventivas.

Análisis de supervivencia

¿Qué queremos saber?	¿Qué buscamos predecir o identificar?	¿Para qué lo usaríamos?
¿Cuándo podrían abandonar?	Tiempo hasta la fuga desde una fecha de corte, considerando también a quienes siguen activos al terminar el seguimiento.	Evaluar la urgencia y anticipación de las acciones.

Clustering

¿Qué queremos saber?	¿Qué buscamos predecir o identificar?	¿Para qué lo usaríamos?
¿Qué perfiles de clientes tenemos?	Grupos con hábitos y comportamientos similares.	Diseñar estrategias diferenciadas según el perfil.

Inferencia causal / uplift

¿Qué queremos saber?	¿Qué buscamos predecir o identificar?	¿Para qué lo usaríamos?
¿En quiénes contactar aumentaría la retención?	Cambio en la probabilidad de permanecer gracias al contacto, comparado con no contactar. Requiere datos de intervenciones y un diseño causal adecuado.	Priorizar a quienes se beneficiarían más de la intervención.

¿Cómo preparar los datos antes de modelar?

El flujo reúne las principales decisiones sobre **nulos**, **valores extremos**, **variables categóricas** y su **compatibilidad con los modelos candidatos**.

No existe una única preparación correcta: **cada decisión depende de los datos y del modelo**.


[Ver flujo de decisiones →](#)

04

Metodología de modelamiento.

Organizar el proceso y evaluar si los resultados son confiables.

CRISP-DM: Cross-Industry Standard Process for Data Mining



05

Caso práctico

Del prompt genérico al prompt informado: cómo trabajar mejor con IA

Caso práctico

Anticipar el churn de clientes

PROBLEMA DE NEGOCIO

Queremos anticipar qué clientes podrían abandonar.

Horizonte: próximos 90 días.

DATOS DISPONIBLES

Histórico de clientes con múltiples variables.

Cada fila representa un cliente.

Target: churn_90d 1 = abandona 0 = permanece

Objetivo: estimar el riesgo de abandono de cada cliente.