

Regularización y estrategias de modelamiento

Qué penalizar, qué ajustar, qué transformar y cuándo combinar modelos.

Sofia Dextre

Hack with DSC | PUCP

- 1 L1, L2 y Elastic Net.
- 2 Regularización según el algoritmo.
- 3 Segmentación, ensambles e híbridos.

01

L1, L2 y Elastic Net

Cómo elegir la penalización según las características de tus variables.

Regularizar es ponerle precio a la complejidad

El modelo sigue buscando minimizar el error, pero algunas soluciones ahora tienen un costo.

$$\text{Objetivo} = \text{Loss} + \lambda \cdot \text{Penalización}(\beta)$$

LOSS

Ajuste a los datos

¿Qué tan bien explica
el modelo lo observado?

λ

Intensidad

¿Cuánto quiero
regularizar?


PENALIZACIÓN

Estructura

¿Qué tipo de solución
quiero castigar?

Regularización Lasso

Penalización L1: favorece soluciones sparse y puede llevar coeficientes a cero.



Las esquinas de la región L1 favorecen soluciones con $\beta_j = 0$.

PENALIZACIÓN L1


$$\text{Loss} + \lambda \sum_{j=1}^p |\beta_j|$$

¿Qué provoca?

- 01 Coeficientes exactamente en 0
- 02 Selección implícita de variables

Regularización Ridge

Penalización L2: reduce los coeficientes de forma suave y favorece soluciones más estables.



La frontera suave de L2 favorece soluciones con coeficientes reducidos, pero normalmente distintos de cero.

PENALIZACIÓN L2


$$\text{Loss} + \lambda \sum_{j=1}^p \beta_j^2$$

¿Qué provoca?

- 01 Coeficientes más pequeños
- 02 Mayor estabilidad ante variables correlacionadas

Regularización Elastic Net

Penalización mixta: combina L1 y L2.



Combina sparsity de L1 con estabilidad de L2.

MEZCLA L1 + L2

$$\text{Loss} + \lambda \left[\alpha \sum |\beta_j| + (1 - \alpha) \sum \beta_j^2 \right]$$

α Mezcla entre L1 y L2

λ Intensidad de regularización

Selección + estabilidad

L1 y L2 en Credit Scoring: ¿qué aportan?

L1 · Parsimonia

$$\beta_j \rightarrow 0$$

Menos variables activas

L2 · Estabilidad

$$|\beta_j| \downarrow$$

Coeficientes más controlados

Explicabilidad

Dirección y contribución

Coeficientes · SHAP

Trazabilidad y monitoreo

Variables → Score → Probabilidad

Reconstruir y revisar el modelo

Hora de practicar

Lasso • Ridge • Elastic Net

[Abrir notebook en Google Colab](#)

02

Regularización implícita

Reducir el sobreajuste sin añadir una penalización al modelo.

Regularización implícita

Reducir el sobreajuste sin añadir una penalización al modelo.

Regularización explícita

$\text{Loss} + \lambda \cdot \text{Penalización}$

Modificamos la función objetivo

L1 · L2 · Elastic Net

Regularización implícita

Loss

Cambiamos cómo aprende el modelo

**Entrenamiento · Stop-
ping · Aleatoriedad**

Early Stopping: saber cuándo detener el entrenamiento

Se usa en modelos que aprenden iterativamente: **Boosting**, redes neuronales y otros algoritmos iterativos.

Ejemplo: Boosting

Iteración 1 + Árbol 1

Iteración 2 + Árbol 2

Iteración 3 + Árbol 3

⋮

Iteración m + Árbol m

Learning rate: cuánto aporta cada nuevo árbol.

¿Cuándo detenernos?



Early Stopping: detener cuando validación deja de mejorar.

Subsample y Colsample: no todos los árboles ven lo mismo

Introducir diversidad durante el entrenamiento puede ayudar a reducir el sobreajuste.

Subsample = filas

10 000 clientes

subsample = 0.8



Árbol 1 → 8 000 clientes

Árbol 2 → otros 8 000

Árbol 3 → otros 8 000

Cada árbol recibe una muestra distinta de observaciones.

Colsample = variables

100 variables

colsample = 0.7



Árbol 1 → 70 variables


Árbol 2 → otras 70

Árbol 3 → otras 70

Cada árbol recibe un subconjunto distinto de variables.

El entrenamiento también elige

Varias soluciones pueden ajustar igual de bien al train, pero no generalizar igual.



	Train	Validación
Solución A	0.95	0.78
Solución B	0.95	0.86

No dejes esa preferencia a ciegas: **valida fuera del train.**

Hora de practicar

Early Stopping • Subsample • Colsample


Abrir notebook en Google Colab

03

Ensembles, Stacking y Modelos Híbridos

Cuándo combinar modelos en lugar de seguir ajustando uno solo.

¿Por qué combinar modelos?



Ensembles: varios modelos, una sola predicción


Un **ensemble** combina varias predicciones en una única salida.



El valor aparece cuando los modelos capturan **información complementaria**.

Bagging

Modelos en paralelo




Diversifica para reducir varianza

Random Forest

Bagging diversifica

Boosting

Modelos secuenciales



Corrige los errores anteriores


XGBoost · LightGBM · CatBoost

Boosting corrige

Stacking: aprender la combinación

El **meta-modelo** aprende cómo combinar las predicciones de los modelos base.



MODELOS BASE



Stacking no promedia: aprende cuándo confiar más en cada modelo.

Importante: el meta-modelo debe entrenarse con predicciones **out-of-fold** para evitar leakage.

Modelos híbridos: una arquitectura diferente



¿Cuándo tiene sentido un modelo híbrido?

1. Patrones distintos entre grupos

La relación entre X e Y no es igual para todas las poblaciones.
Segmentación → especialistas

2. Hay reglas conocidas

Restricciones, políticas o casos que no necesitan ser aprendidos.
Reglas + ML

3. Existen objetivos que compiten

Por ejemplo: interpretabilidad vs. capacidad predictiva.
Score + modelo flexible

4. Un modelo no captura todo

Distintas partes del problema requieren mecanismos diferentes.
Arquitectura especializada

Hora de practicar

Ensembles • Stacking • Modelos híbridos

[Abrir notebook en Google Colab](#)